

Parcialito V

La famosa banda de rock “Eruca Sativa” está buscando lugares donde presentar su nuevo hit “Lío”, con el objetivo de estar en las últimas provincias del país en las que no han tocado aún. Para ello utilizan una base de datos relacional con el siguiente esquema:

- Antros(id_antro, nombre, dirección, ciudad, provincia, capacidad)
- Disponibilidad (id_antro, fecha)

Se busca disponibilidad para 50 mil personas en 5 días de enero, con la siguiente consulta:

```
SELECT a.id_antro, a.nombre FROM antros a INNER JOIN disponibilidad d
USING(id_antro) WHERE (a.provincia = 'Catamarca' OR a.provincia = 'La Rioja') AND
a.capacidad >= 50,000 AND (d.fecha BETWEEN '2025-01-06' AND '2025-01-10')
```


ANTROS	DISPONIBILIDAD
n(antros) = 10.000	n(disponibilidad) = 100.000
B(antros) = 2.000	B(disponibilidad) = 5.000
V(provincia, antros) = 20	V(id_antro, disponibilidad) = 10.000
	V(fecha, disponibilidad) = 100
H(I(provincia, antro)) = 2	H(I(id_antro, disponibilidad)) = 4
	H(I(fecha, disponibilidad)) = 3

Estime el **costo** de realizar esta consulta y la cantidad de **filas** que serán devueltas, contando la información de catálogo y sabiendo que:

- Se dispone de 100 bloques de memoria disponibles para la operación
- Que los índices indicados no son de clustering
- Que un 10% de los antros tienen capacidad para al menos 50 mil personas.

Evalúe diferentes alternativas e indique la que tiene el menor costo.

Resolución:



R: ANTROS

S: DISPONIBILIDAD

Primero hago la selección:

$R' = \sigma(\text{provincia}='La Rioja' \text{ OR } 'Catamarca') \text{ AND } (\text{capacidad} \geq 50000) (R)$

Cost(σ capacidad(R)):

-FileScan = B(R) = 2000

-IndexScan = No tiene índice

Cost(σ provincia(R)):

-FileScan = 2000

-IndexScan = $H(I(A,R)) + \lceil \frac{n(R)}{V(A,R)} \rceil$

$= 2 + 10000 / 20 = 502 * 2 = 1004$ (porque es un OR entre dos valores; se hace el índice 2 veces)

El costo es menor por provincia, por lo que $COST(\sigma \text{provincia}, \text{capacidad}(R)) = 1004$

$n(R') = (10000 * 2 / 20) * 0.1 = 100$ (2 porque se toman 2 provincias de las 20 y 0.1 porque hay 10% con cap ≥ 50000)

$$F(R) = 10000 / 2000 = 5$$

$$B(R') = 100 / 5 = 20$$

Ahora hago el JOIN $R' \bowtie S$:

$$M = 100$$

Loops anidados por bloque:

$$\begin{aligned} \text{COST}(R' \bowtie S) &= \text{roundup}(B(R')/(M-2)) * B(S) \\ &= 1 * 5000 = 5000 \end{aligned}$$

Loop con único índice:

$$\begin{aligned} \text{COST}(R' \bowtie S) &= n(R') * (H(I(A,S)) + \lceil n(R')/V(A,S) \rceil) \\ &= 100 * (4 + 100000/10000) = 1400 \end{aligned}$$

Sort-Merge:

$$\begin{aligned} \text{COST}(R' \bowtie S) &= B(S) + 2 * B(R') * \lceil \log_{M-1}(B(R')) \rceil + 2 * B(S) * \lceil \log_{M-1}(B(S)) \rceil \\ &= 10000 + 2 * 20 * 1 + 2 * 10000 * 1 = 30040 \end{aligned}$$

Hash:

$$-p \leq 99$$

$$-\min(1; 51) \leq 98$$

$$\begin{aligned} \text{COST}(R' \bowtie S) &= 2 * B(R') + 3 * B(S) \\ &= 2 * 20 + 3 * 5000 = 15040 \end{aligned}$$

-Mejor costo Loop con único índice; uso ese.

$$n(R' \bowtie S) = 100 * (100000 / 10000) = 1000$$

$$F(R' \bowtie S) = 5 * 20 / (5 + 20) = 4$$

$$B(R' \bowtie S) = 1000 / 4 = 250$$

Por último hago la selección por fecha llamaré W a $R' \bowtie S$

$\sigma_{\text{fecha}}(W)$:

-FileScan = 0 (aprovecho el uso de pipeling)

Como la proyección no precisa evitar duplicados, se puede hacer sin costo extra a la salida de cualquier operador. Por lo que costo de la proyección = 0

$$\text{Costo total} = 1400 + 1004 = 2404$$

cant de filas devueltas: $n(W) = 1000 * 0.05 = 50$ (0.05 porque de 100 ($V(\text{fecha}, W)$) fechas tomo 5 (rango acotado))

Si tomo otra alternativa de seleccionar por fecha en los primeros pasos (es decir, seleccionar por fecha, luego hacer el join y de eso seleccionar la provincia y capacidad):

$\sigma_{\text{fecha}}(S)$:

-Por FileScan = 5000

112180 - Facundo Madotta

-Por IndexScan = $3 + 100000 * 5/100 = 5003$. Tomaría FileScan pero el costo ya sería mayor, que la primera alternativa propuesta